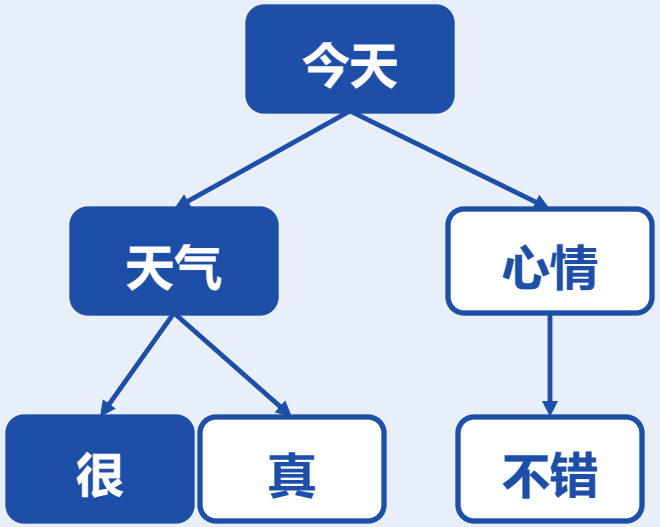
如何让大模型生成得更快

投机解码的原理、挑战与前沿

胡时京
复旦大学计算与智能创新学院

从逐词生成，到并行验证

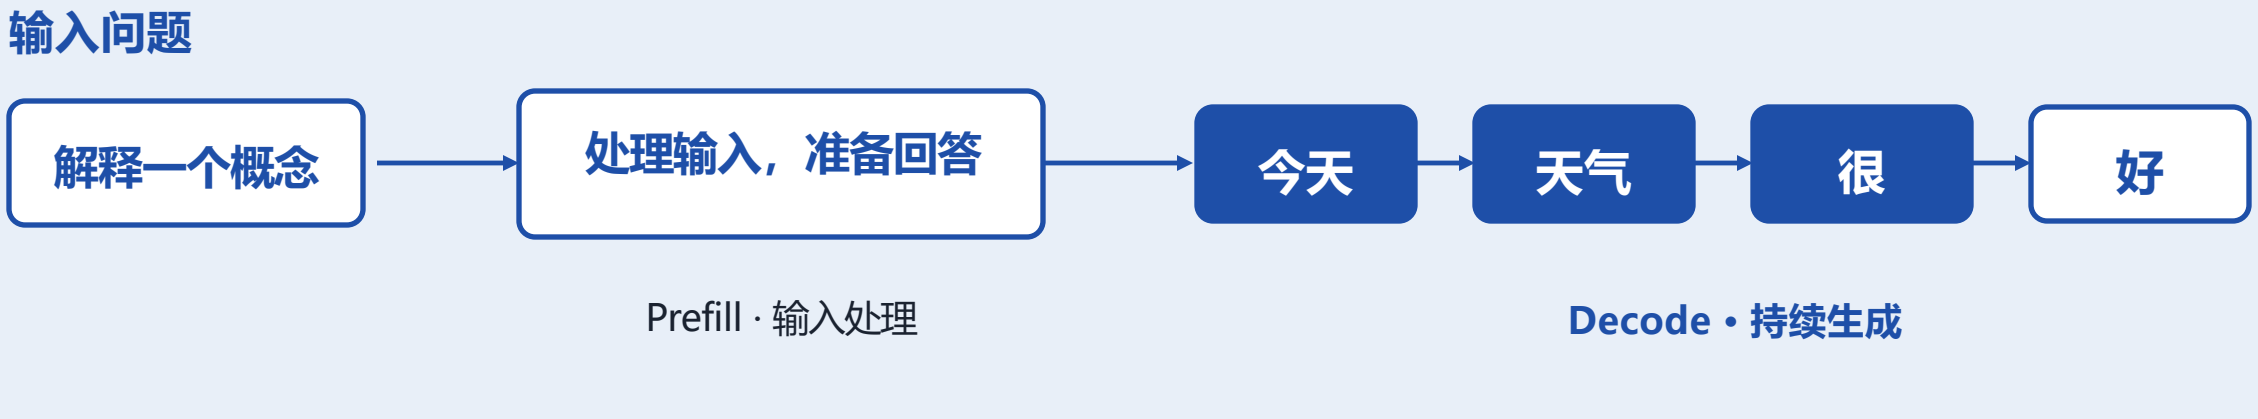
一份草稿，多种可能



提出候选 → 验证 → 继续生成

从等待回答，到推理加速

模型的回答，要经过两个不同的阶段



这里的“推理”是训练完成后的模型运行，
不只指解题时的逻辑推理。

本报告重点：后续文本的生成速度

适用于聊天、代码与长篇输出

问题不是“能否回答”，而是“能否更快地生成回答”。

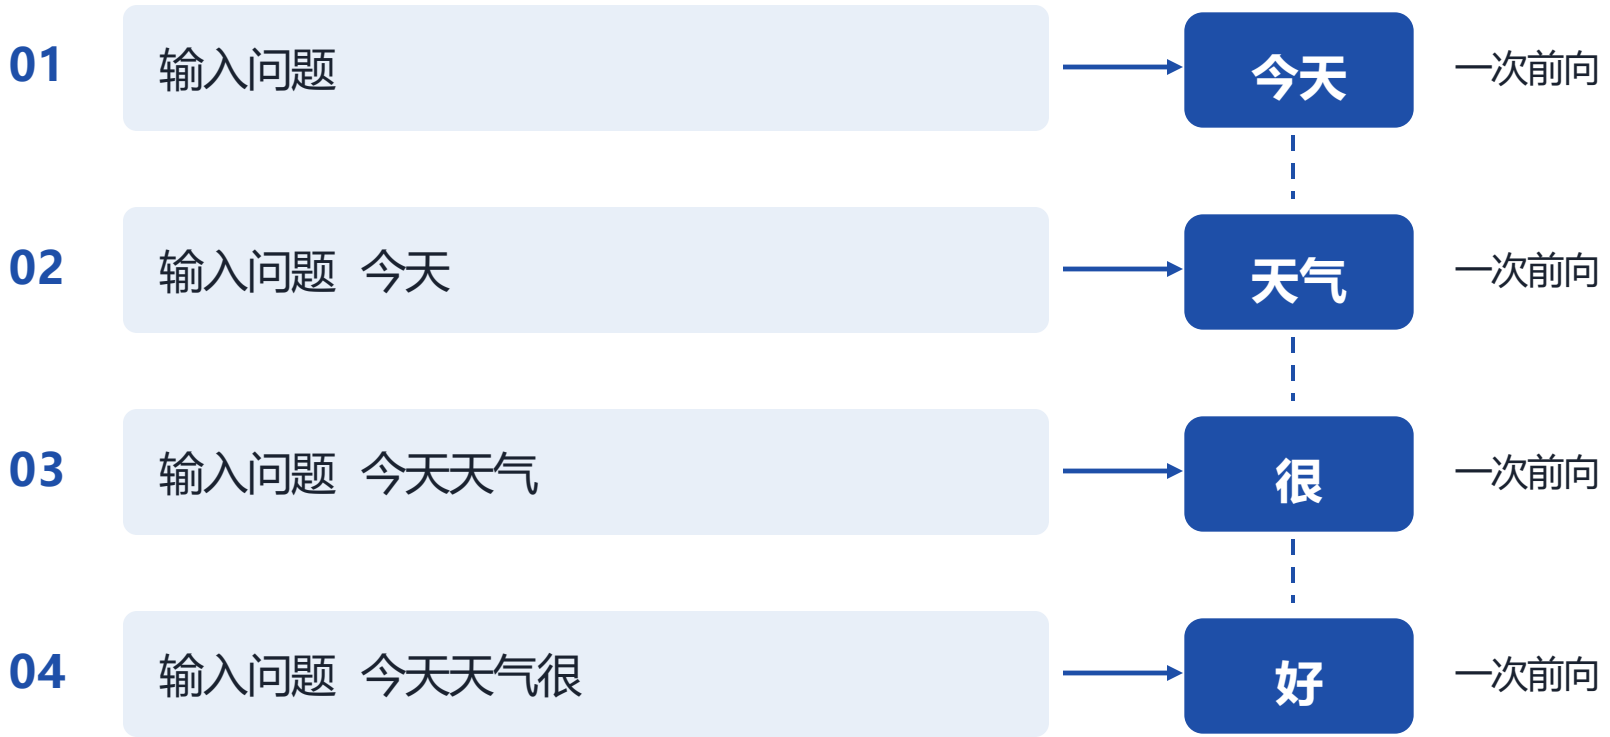
为什么不能一次生成整句话?

词元 Token

模型处理文本的
基本单位。

一个词元未必是
一个汉字或一个词。

下面按词语切分，
仅为教学示意。



硬件擅长并行，但下一个词元依赖已经生成的前缀。

GPU 算力与访存的差距：以 A100 为例

A100 80GB SXM | BF16 Tensor Core 密集计算（不使用稀疏性翻倍值）

峰值计算能力

312 万亿次运算 / 秒

312 TFLOPS

显存带宽 HBM2e

2.039 万亿字节 / 秒

2.039 TB/s

同一工作量换算成时间：8B 参数、BF16、单请求生成 1 个词元

读取 16 GB 权重 — **7.85 ms**

完成约 16 GFLOPs — **0.051 ms（理想）**

≈153×

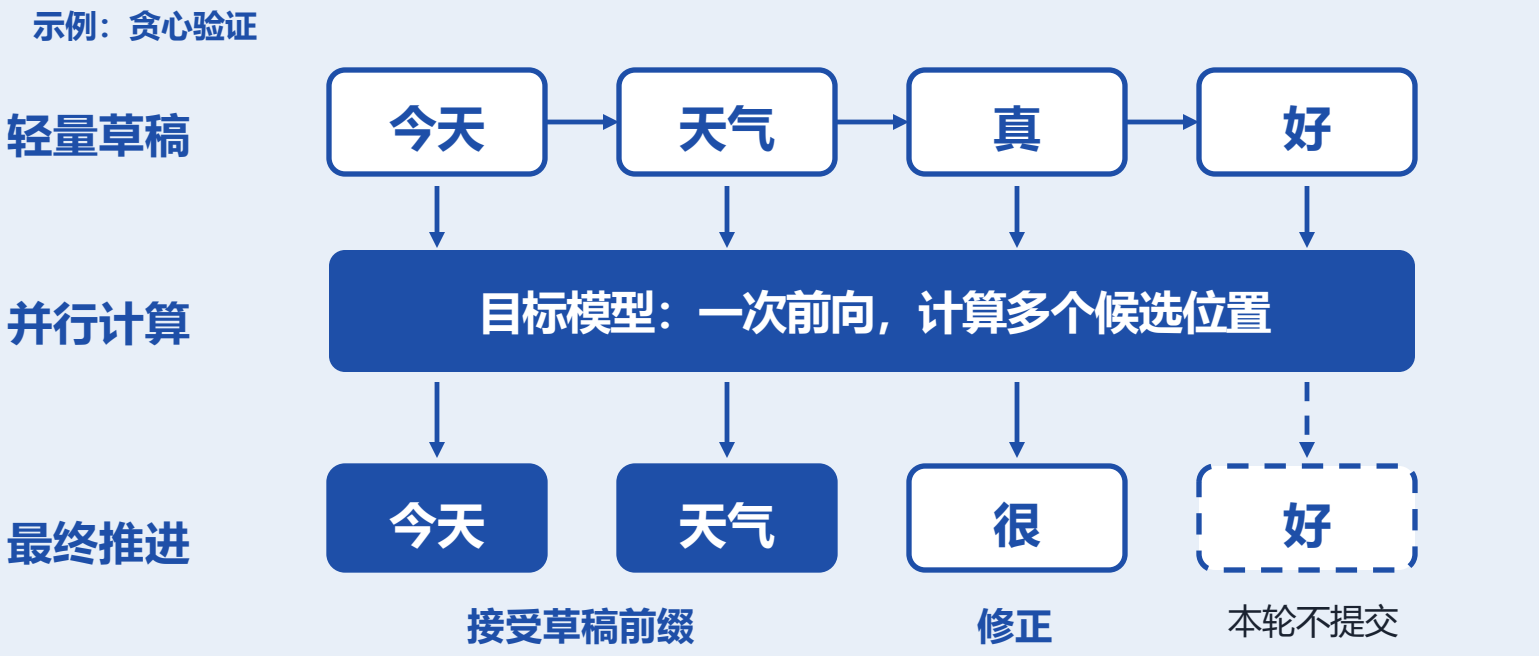
理想访存 / 计算用时

多个候选共享权重读取，才能让原本闲置的计算能力发挥作用。

权重复用提高算术强度；153× 是上述理想用时之比，不是投机解码加速比。

NVIDIA A100 数据表；理想峰值估算，非实测。仅计权重相关线性层，忽略 KV、激活与调度等开销。

投机解码：先打草稿，再并行验证



候选并不是答案；目标模型决定哪些内容可以提交。

为什么能并行?

候选已经给出，
各位置的候选前缀已知。

为什么可以无损?

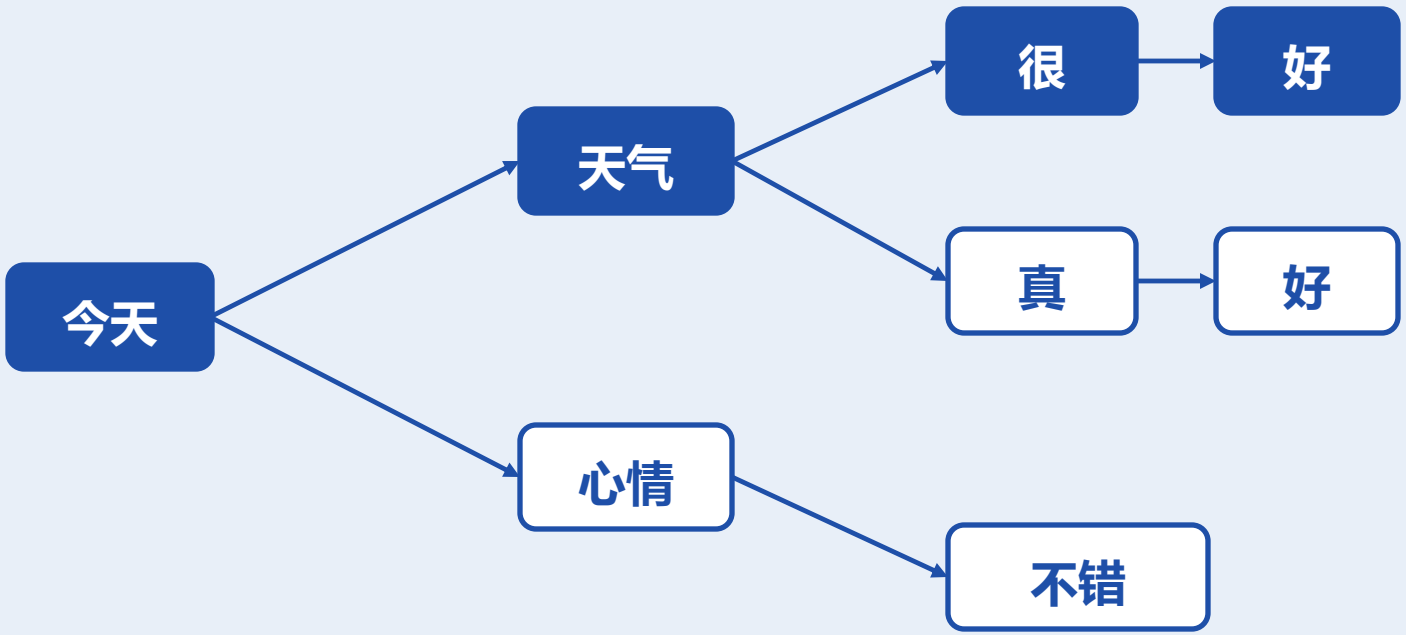
严格的验证与采样规则，
保持目标输出分布不变。

不是事实核查，
也不保证每次输出同一句话。

用便宜的草稿，换取权重复用与更少的目标模型串行步骤。

从一条草稿，到一棵候选树

同一前缀，多种续写



共享前缀，不必把每条候选完整重复存储。

多准备几条路

一条续写不合适，
还可能接受另一条。

但预算不是无限的

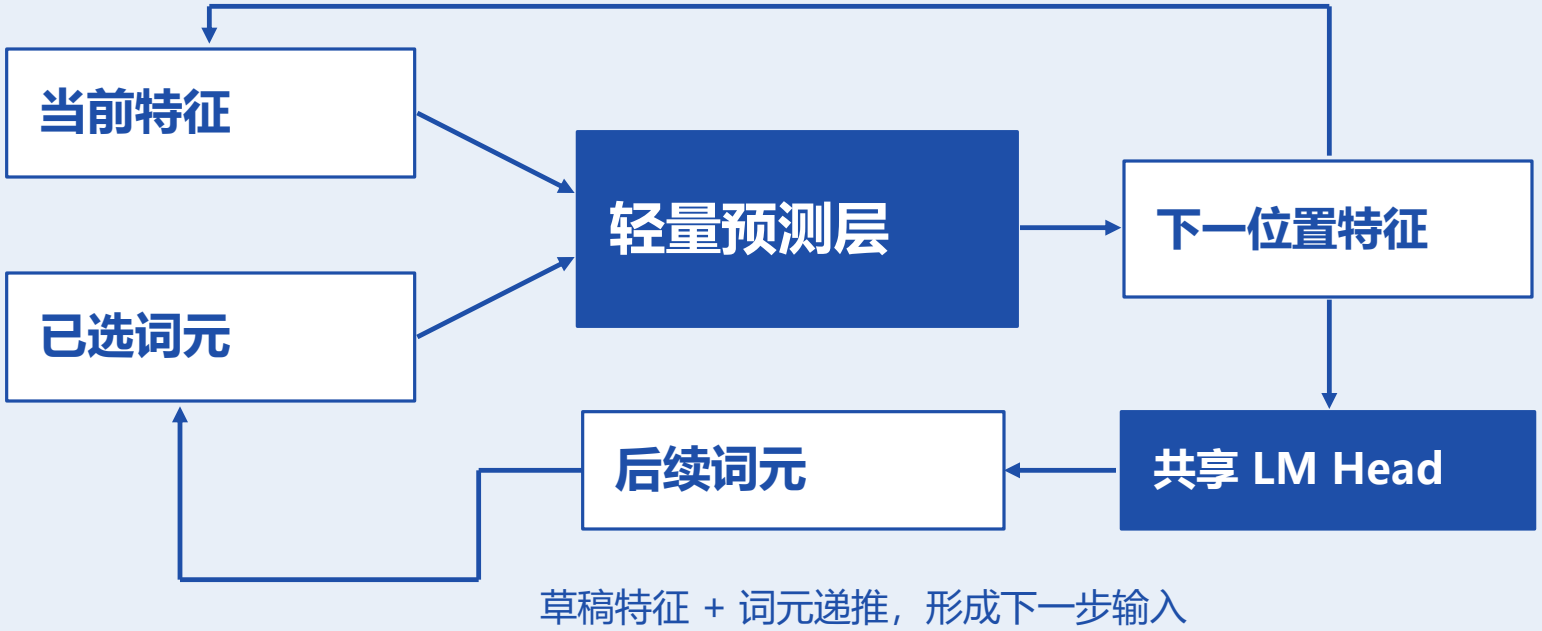
候选越多，
草稿与验证开销也越大。

更多接受量 ≠ 必然更快

有限预算下：把候选放在更可能有用的分支上。

EAGLE：借助目标特征，轻量地逐步打草稿

关键思路：目标模型已经算出的特征，不要浪费。



为什么比大模型便宜?

只运行轻量草稿层，
复用目标模型的特征、
Embedding 和 LM head。

为什么还会有瓶颈?

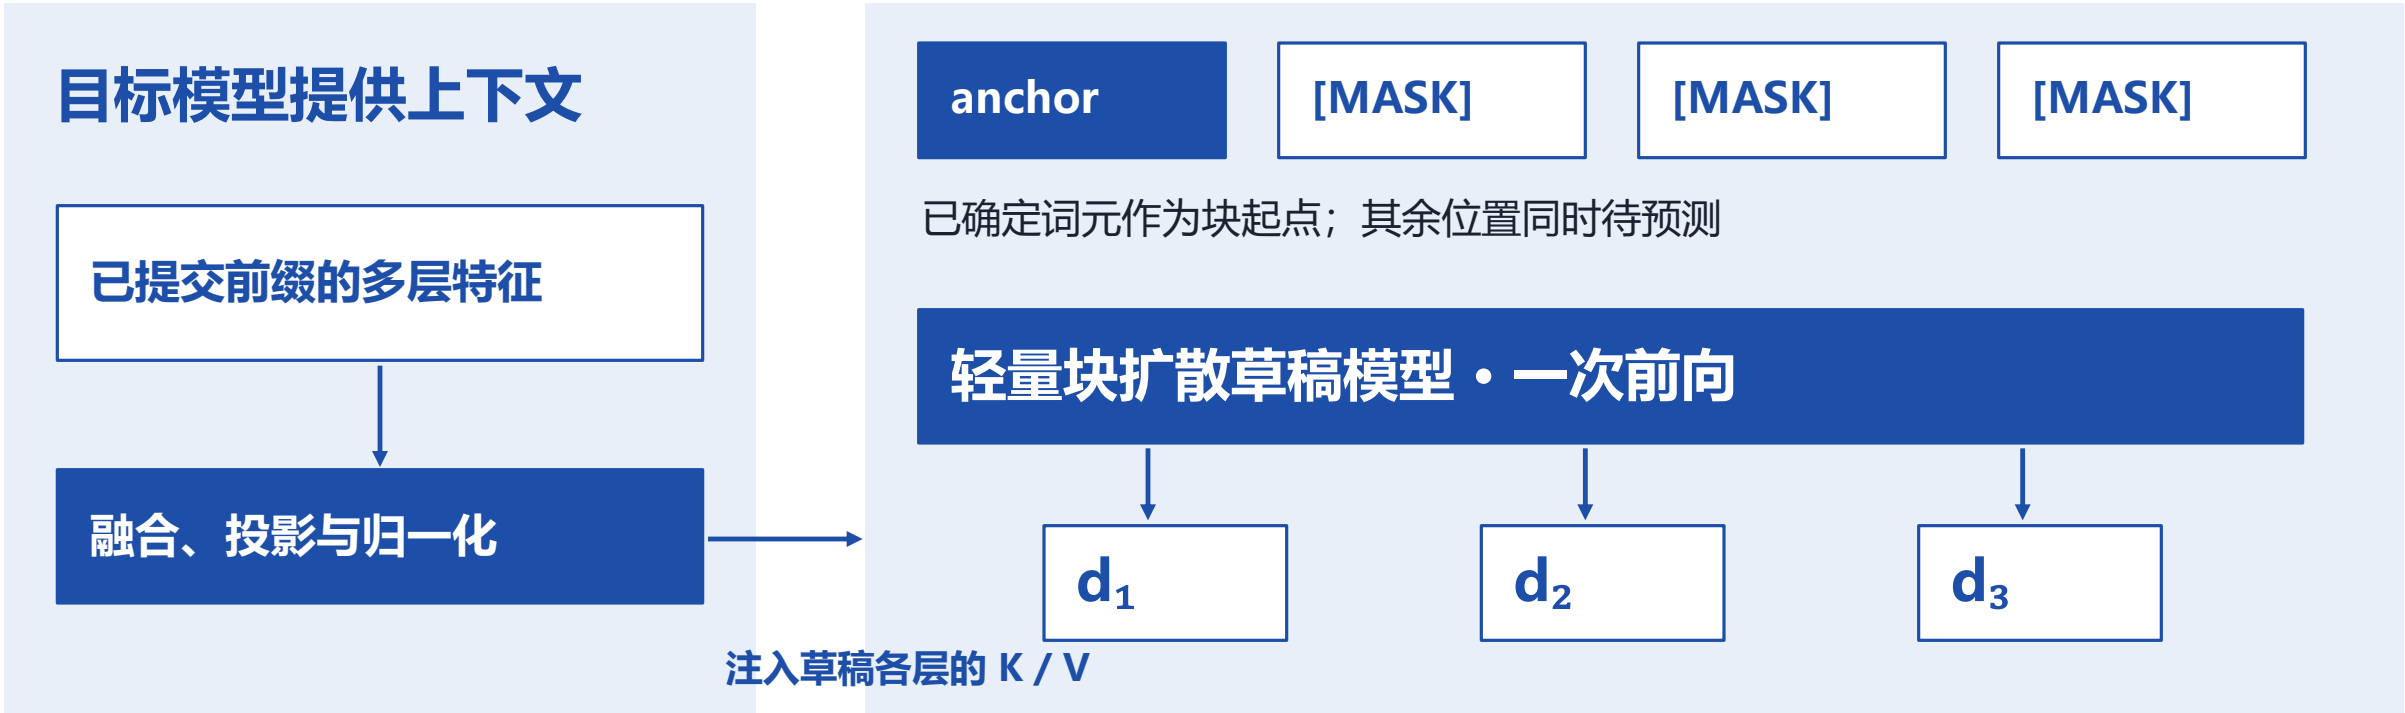
沿深度仍需逐步生成，
预测误差也会累积。

EAGLE-2 改为动态树；EAGLE-3 改进特征融合与训练，但仍采用逐步草稿。

来源：EAGLE, ICML 2024；EAGLE-2, EMNLP 2024；图为结构简化示意

DFlash：让草稿模型也一次预测多个位置

从“轻量地逐步猜”，转向“一次前向并行猜一块”。



目标模型仍负责验证；DFlash 加快草稿过程，不把目标模型改成扩散模型。

来源：DFlash: Block Diffusion for Flash Speculative Decoding，ICML 2026，§3

发展脉络①｜从特征预测，到动态树与训练改进

三代方法分别改进“怎么猜”“猜哪些”“怎样训练”。

2024.01

EAGLE-1

特征层面的自回归草稿

利用目标模型特征，
结合词元信息预测后续。

2024.06

EAGLE-2

上下文感知的动态树

根据草稿置信度，
扩展并筛选候选分支。

2025.03

EAGLE-3

多层特征 + 训练时模拟

不再强制拟合目标特征；
直接预测词元，模拟多步草稿。

共同特点：
草稿仍逐步自回归生成。

GRIFFIN 对标 EAGLE-2

词元与特征的训练—推理对齐

GTO 对标 EAGLE-3

单路径训练 → 树策略训练

虚线表示我们的研究定位，不表示方法继承；GRIFFIN 实验也比较 HASS。

来源：EAGLE arXiv:2401.15077；EAGLE-2:2406.16858；EAGLE-3:2503.01840

发展脉络②｜并行草稿与系统自适应并行推进

后续关注：草稿自身的串行开销、块内依赖，以及不同负载下的成本。

DFlash • 2026.02

块扩散草稿
一次前向并行提出一块候选
利用目标模型的上下文特征

DSpark • 2026.07

并行主干 + 轻量顺序修正
按置信度与负载调整验证长度

并行主干不等于
全流程没有顺序操作。

DFlash2 • 2026.08

局部卷积 + 候选对并行打分
再进行轻量的顺序路径选择

TEV / ExitTrain 对标 DFlash

具体基线：DFlash + DDTree；优化树覆盖与验证执行。

EAGLE-4 • 2026.10

延续 EAGLE 自回归树路线
滑窗草稿层、低秩候选头
按实测成本适配硬件与批量

不是一条“版本替代链”：草稿质量、并行度与运行成本是不同的优化维度。

来源：DFlash:2602.06036；DSpark:2607.05147；Inco DFlash2；EAGLE-4 官方架构文档

GRIFFIN：让训练更贴近实际生成

GRIFFIN • NeurIPS 2025

对标 EAGLE-2：缓解词元与特征错位

训练阶段	训练数据中的词元	训练使用的特征	→ 草稿模型学习预测
实际生成	自身生成的词元	自身生成的特征	→ 误差可能逐步累积

同一个模型，训练和使用时却可能面对不同的输入。

对齐感知训练

根据词元对齐程度筛选训练信号，
减轻严重错位样本的干扰。

词元引导融合

将词元信息融入特征预测，
缓解词元与特征之间的不一致。

不仅要学得好，还要让训练情境接近使用情境。

GRIFFIN: Effective Token Alignment for Faster Speculative Decoding

第一作者：胡时京（Shijing Hu） | NeurIPS 2025

GRIFFIN 方法①｜只在可对齐的前缀上继续学习

前面的草稿已经偏离，后面的训练信号还可靠吗?

教学示例：训练标签是否落入草稿 top-k 候选



在第 3 步发现错位，屏蔽依赖它的后续损失。

多轮草稿特征回填

训练时使用前面生成的草稿特征，接近实际解码。

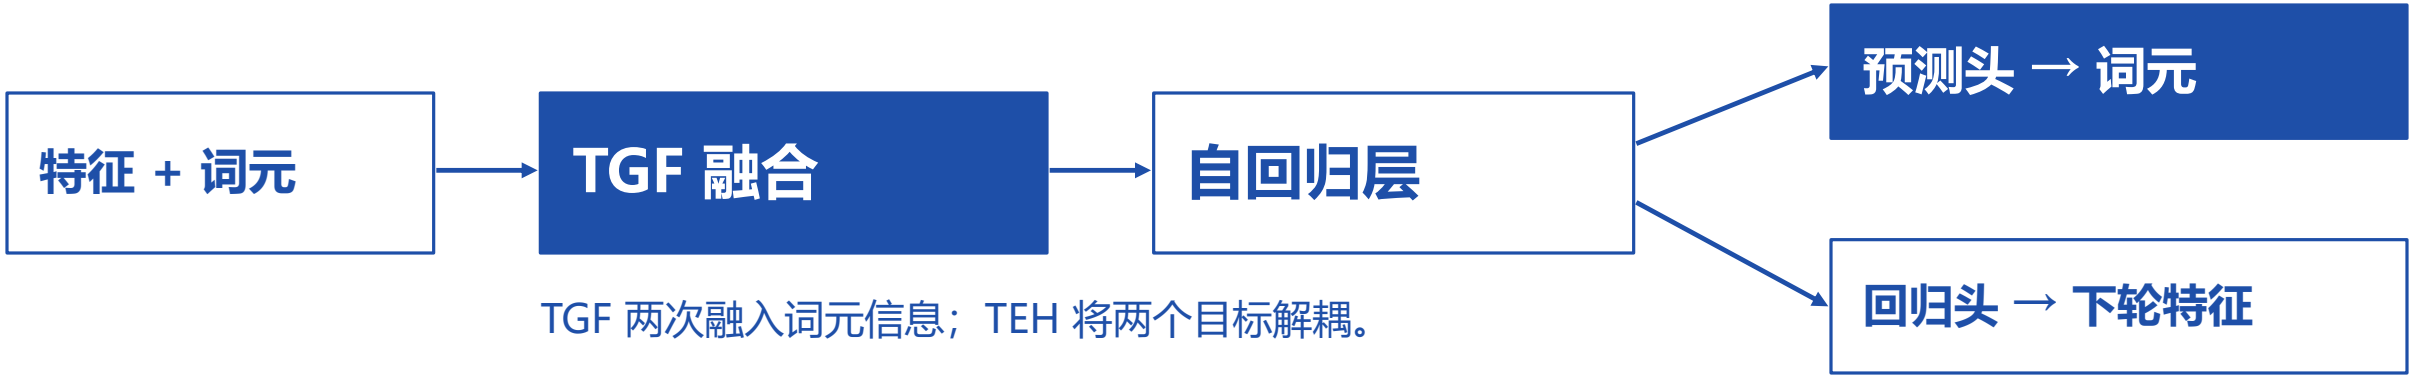
累积对齐掩码

任一前序位置未命中，后续相关损失不再回传。

top-k 命中是训练筛选条件，不等于目标模型验证时一定接受。

GRIFFIN 方法② | 词元引导融合，双头分工

让特征更贴近词元，同时分开“预测词元”和“生成递推特征”。



TGF 两次融入词元信息；TEH 将两个目标解耦。

LLaMA3-Instruct-8B • MT-Bench • T=0 • Batch=1 • 单张 A100 80GB

方法	加速比（相对 AR）	平均接受长度
EAGLE-2	2.56×	4.18
HASS	2.75×	4.63
GRIFFIN	**3.09×**	**4.85**

训练策略与草稿结构协同，改进能体现在实际解码速度上。

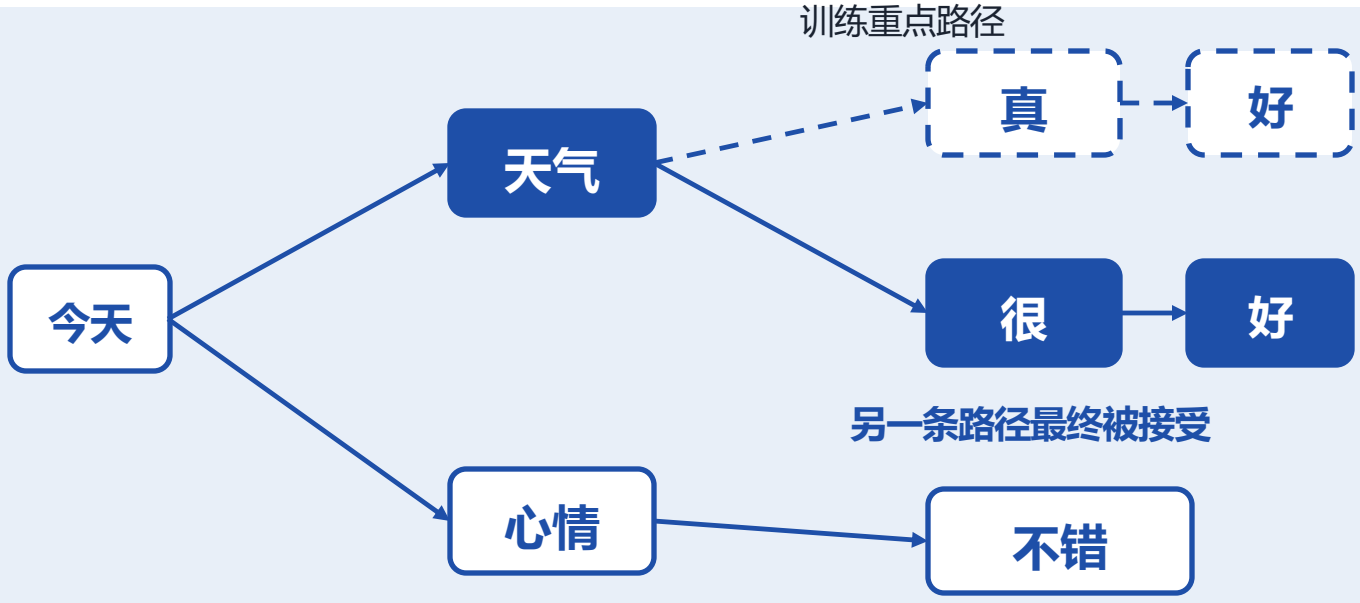
GRIFFIN: Effective Token Alignment for Faster Speculative Decoding

第一作者：胡时京（Shijing Hu） | NeurIPS 2025

GTO：使用一棵树，就围绕整棵树训练

GTO • ICLR 2026

对标 EAGLE-3：从单路径目标转向树策略



评价整棵树

根据分支的期望接受长度，
构造树级奖励。

用比较指导训练

比较当前模型与参考模型，
以组间信号稳定优化。

从单路径预测，转向树式策略优化

目标不是“某条路预测得准”，而是“整棵树更有用”。

Bridging Draft Policy Misalignment: Group Tree Optimization for Speculative Decoding

第一作者：胡时京（Shijing Hu） | ICLR 2026

GTO 方法①｜让树的“有用程度”进入奖励

不是只问下一词元对不对，而是问候选分支能连续推进多远。

两步分支示意（目标模型概率）



走到 A：0.9
走到 A→B：0.9 × 0.8 = 0.72

分支期望长度

$$L = 0.9 + 0.72 = 1.62$$

再聚合为树级奖励

用 log-sum-exp 偏重高分分支，
形成可用于训练的代理奖励。

GTO 的分支聚合奖励是训练代理，不等同于 TEV 的固定树覆盖恒等式。

GTO 方法②｜先与参照比较，再稳定更新

只比较绝对奖励，会把“题目简单”误当成“模型变强”。

同一前缀，两棵树

当前草稿模型 → 当前树

冻结参照模型 → 参照树

改进量 = 当前奖励 − 参照奖励

① 相邻前缀组成一组

同序列相近位置共享较多上下文，便于比较。

② 标准化组内改进量

先减去参照奖励，再在组内标准化。

③ 裁剪更新 + 词元损失

沿最长接受序列构造 PPO 式代理，限制更新幅度。

比较树的整体质量，同时用受限更新与词元监督保持训练稳定。

Bridging Draft Policy Misalignment: Group Tree Optimization for Speculative Decoding

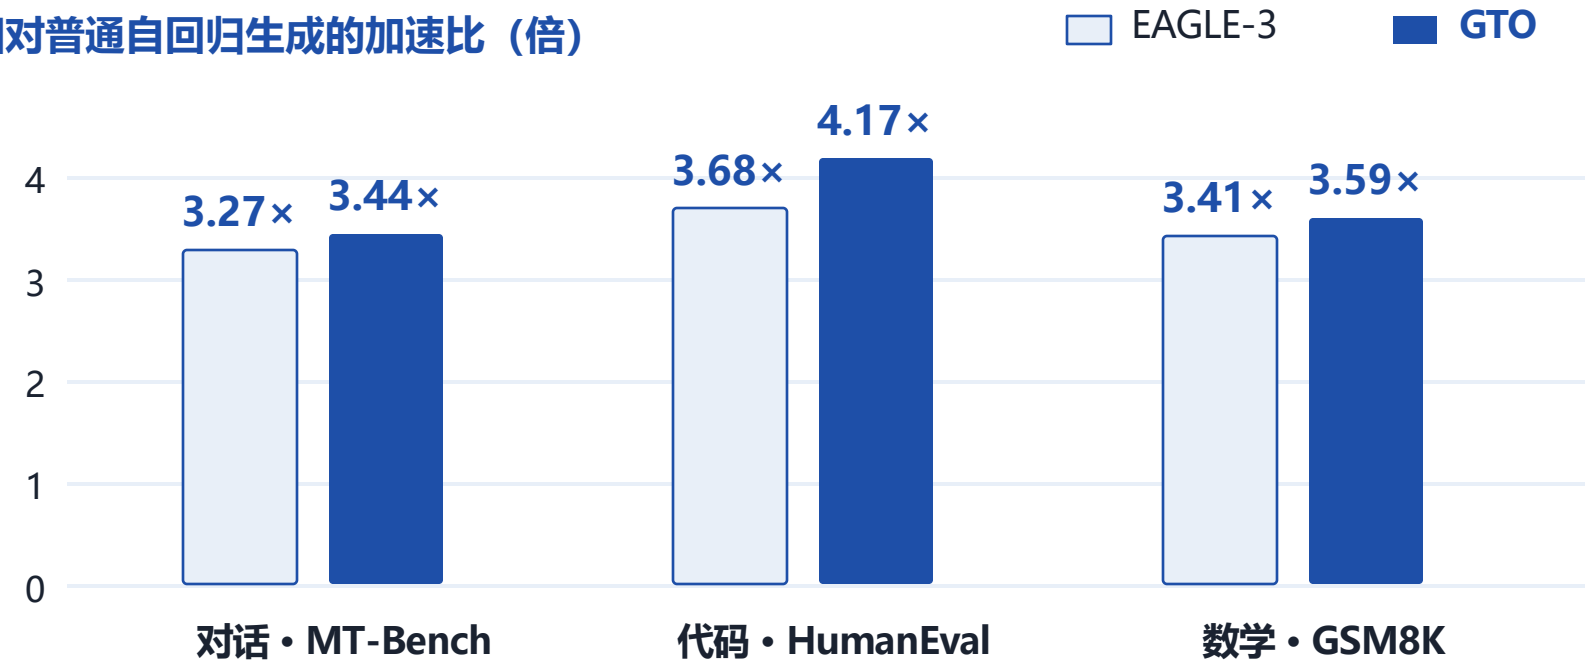
第一作者：胡时京（Shijing Hu） | ICLR 2026

GTO 结果 | 从训练改进，到实际速度提升

GTO 代表性结果：在已有强基线上，继续获得增量提升

LLaMA-3.1-Instruct-8B · 温度 0 · Batch = 1 · 单张 NVIDIA A100 80GB

相对普通自回归生成的加速比（倍）



同一模型 • 三任务平均

3.46×

→ 3.73×

接受长度：6.07 → 6.52

不是服务器并发吞吐指标

接受更多只是中间指标；最终要用实际运行速度检验。

Bridging Draft Policy Misalignment: Group Tree Optimization for Speculative Decoding

第一作者：胡时京（Shijing Hu） | ICLR 2026

TEV：先看清上限，再寻找优化空间

TEV / ExitTrain • 在研

对标 DFlash：树覆盖与验证如何优化?

固定树的精确路径验证框架



有些可能的续写，根本不在树里。

已有代表性验证器已达到固定树上界

接受更多：改善树的覆盖

ExitTrain：利用目标反馈调整草稿训练，
让有限候选更贴近目标模型。

执行更快：减少验证开销

TEV：更直接地实现相同的接受规律。

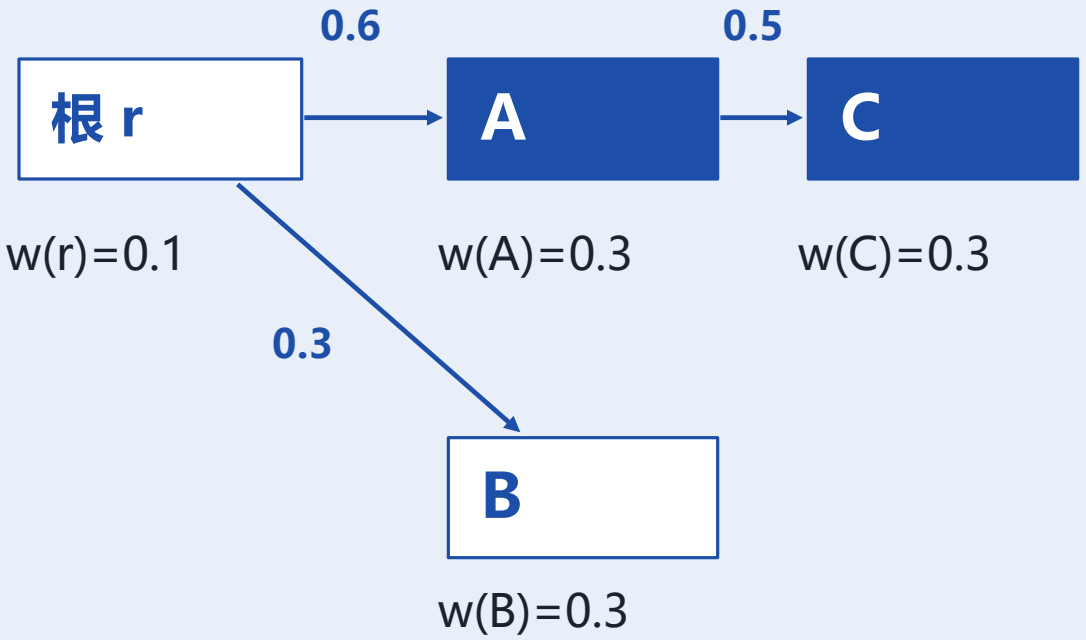
理论划清边界：更好的树提高接受量，更高效的实现降低开销。

Where Draft Trees Lose Target Mass: Exit-Guided Speculative Decoding

第一作者：胡时京（Shijing Hu） | ICLR 2027（在审）

TEV 方法①｜先抽“在哪里退出”，再补一个词元

退出概率 = 到达该节点的概率 × 下一步离开候选树的概率



① 一次抽取退出节点

$w(v) = P(v) \cdot \rho(v)$

$\rho(v)$：未被子节点覆盖的目标概率

② 在退出点抽取 bonus

排除已在树中的子词元，再从残差分布采样。

根→退出节点的路径 + bonus 构成输出块。

同一棵树：饱和验证器的接受规律相同，TEV 改变的是实现方式。

TEV 方法②｜把退出反馈用来训练更好的候选树

验证规则已达上限，进一步增加接受量，需要改变树的覆盖。

当前草稿

用真实推理的构树策略
生成有限预算候选树

→

冻结目标模型

按各节点真实父前缀
计算退出权重 w(v)

→

加权训练

固定本轮树与目标权重
只更新草稿参数

→

下一轮树

改变候选分数与优先级
重新分配有限树预算

节点级辅助信号

$$L_{exit} \propto -\sum w(v) \log q_\theta(x_v)$$

仍保留常规词元学习

$$L = L_{tok} + \lambda_{exit} L_{exit}$$

这是引导树预算分配的训练代理，不是离散构树过程的精确梯度。

Where Draft Trees Lose Target Mass: Exit-Guided Speculative Decoding

第一作者：胡时京（Shijing Hu） | ICLR 2027（在审）

TEV 结果 | 把“树变好”和“验证更快”分开测

Qwen3-4B • T=1 • 非根节点预算64 • Batch=1 • 单张 H20 96GB

四任务平均：MT-Bench / HumanEval / GSM8K / MATH-500

草稿模型	验证方法	加速比 SR	输出块长度 τ
原始 DFlash	Predraw	4.95×	7.08
原始 DFlash	TEV	4.97×	7.09
ExitTrain 后	Predraw	5.55×	8.05
ExitTrain 后	**TEV**	**5.59×**	**8.06**

τ 含一个 bonus；同草稿下两种验证的微小差异来自独立有限样本。

接受长度的主要增益来自训练；验证执行优化的端到端增益更小。

更快，
不只是换一个
更小的模型。

而是重新组织
猜测、验证与学习。

01 少做串行步骤

先提出候选，再并行验证。

02 对齐实际解码

训练目标要服务真实使用方式。

03 看清优化边界

更好的候选，更高效的执行。

谢谢，欢迎交流。

备份｜无损，不是每次输出同一句话

“无损”的含义

保持目标模型的
输出概率分布。

不等于消除幻觉；
不等于每次同一句；
不等于只匹配最大概率词。

二元示例：两种算法都应产生同一目标分布

目标 p：A = 0.7，B = 0.3；草稿 q：A = 0.5，B = 0.5



标准单链拒绝采样：

A 总是接受；B 以 0.3 / 0.5 = 0.6 的概率接受。

拒绝 B 的概率为 0.2；残差补为 A，得到 0.7 / 0.3。

示例说明概率修正；不能把贪心匹配直接当作随机采样验证。

教学示例；标准单链拒绝采样 α(x)=min(1,p(x)/q(x))；与主讲固定树定理区分

备份 | 树级训练目标与固定树覆盖

两种量作用不同：训练代理奖励 ≠ 固定树的精确覆盖恒等式

GTO · 分支期望长度聚合

以分支级信号构造树级奖励，
配合组间比较进行训练。

$$L_i = \sum_j \prod_{k=1}^{j} p(x_{i,k} \mid \mathrm{prefix}_{i,k})$$

$$R(T) = (1/\eta) \log \sum_i \exp(\eta L_i)$$

TEV · 固定树的覆盖上界

P(u)：目标模型走到节点 u 的概率
D：接受的草稿词元数
L：加上一个 bonus 的输出块长度

$$E[D \mid T] \le \sum_{u \neq \mathrm{root}} P(u)$$

$$E[L \mid T] = 1 + E[D \mid T]$$

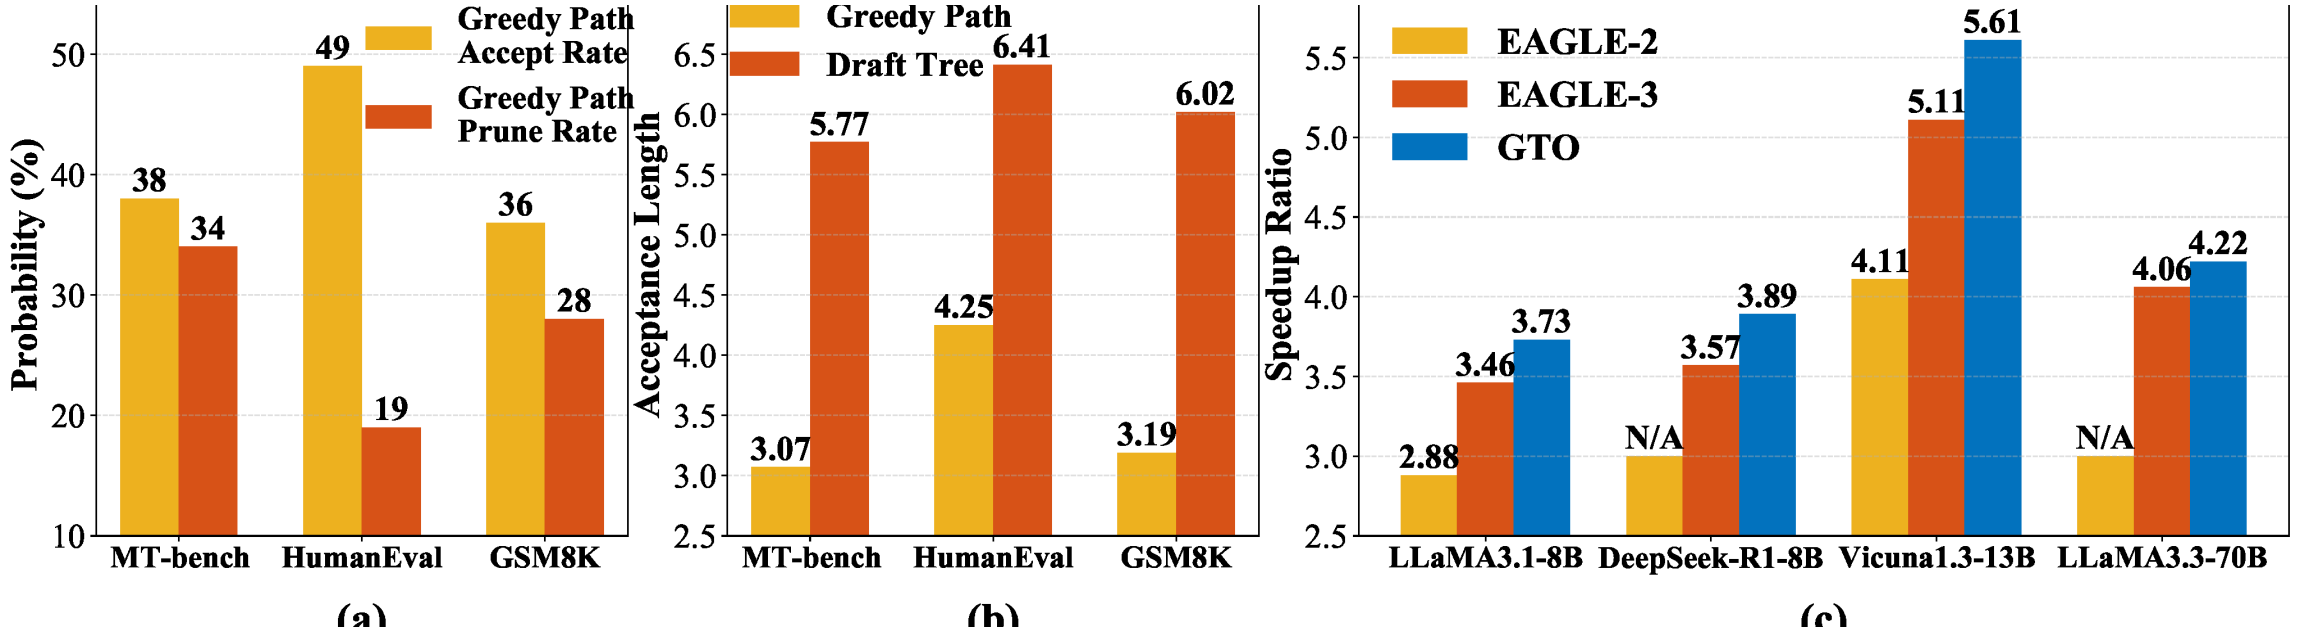
饱和验证器在上式取等号；不能重复计算共享前缀。

限定：固定前缀树、条件精确的路径验证；D 与 L 的口径不可混用。

来源：GTO §3.1；TEV 在研稿固定树界；P(u) 在节点真实父前缀下计算

备份｜实验设置与论文原始证据

GTO 论文原图：训练路径错位与多模型结果



MT-Bench	加速比 3.27× → 3.44×	接受长度 5.77 → 6.15
HumanEval	加速比 3.68× → 4.17×	接受长度 6.41 → 6.95
GSM8K	加速比 3.41× → 3.59×	接受长度 6.02 → 6.47

下表：EAGLE-3 → GTO；LLaMA-3.1-Instruct-8B，T=0，Batch=1，A100 80GB。

来源：GTO Figure 2 / Table 1；原始图保留论文坐标范围；主讲第17页柱形图从0起绘制